

גרסה- תרגול 3 :

מטריצת הטלה, המודל הלינארי והתפלגויות משותפות :

מטריצת הטלה אורתוגונלית

מטריצה איידמפוטנטית היא מטריצה $A \in R^{n \times n}$ שדרגתה r המקיימת $A = A^2$.

מטריצה סימטרית ואיידמפוטנטית נקראת **מטריצת הטלה אורתוגונלית**.

טענה- העי"ע של מטריצת הטלה הם 1, בריבוי כדרגת המטריצה, ו-0 בריבוי השווה למימד של גרעין המטריצה.

הוכחה : תרגיל

מטריצת הטלה למרחב הנפרש על ידי עמודות X :

תהי $X \in R^{n \times p}$ מטריצה מדרגה מלאה ונגדיר $P_X = X(X^T X)^{-1} X^T$. הראו כי P_X היא מטריצת הטלה למרחב הנפרש על ידי העמודות של X . כלומר :

$$(1) \quad P_X \text{ סימטרית.}$$

$$(2) \quad P_X \text{ איידמפוטנטית.}$$

$$(3) \quad P_X v \in IM(X) : v \in R^n \text{ שלכל}$$

הוכחה : תרגיל

המרחב המשלים האורתוגונלי : יהי $U \subseteq V$ תת מרחב. נגדיר את תת המרחב המשלים האורתוגונלי של U באופן הבא :

$$U^\perp = \{v \in V | u^T v = 0, \forall u \in U\}$$

$$\text{טענה : } U \oplus U^\perp = V$$

הוכחה :

ניקח $v \in V$. אז $v = P_U v + v - P_U v = P_U v + (I - P_U)v$. בתרגיל תראו כי לכל וקטור $u \in U$ ההטלה של u לתת המרחב U היא u עצמו, ומכאן שלכל וקטור $u \in U$ נקבל $u^T (I - P_U)v = u^T v - u^T P_U v = u^T v - u^T P_U^T v = u^T v - (P_U u)^T v = u^T v - u^T v = 0$ $U \cap U^\perp = \{0\}$ ולכן הסכום ישיר.

מצד שני- כיוון ש- U ו- U^\perp מוכלים ב- V כי תתי מרחבים שלו, אז גם הסכום הישר שלהם מוכל ב- V כי הוא מרחב.

תכונות חשובות-אולי הכי חשובות בקורס(!!!)-של מטריצת הטלה:

Proposition 4. Let X be an $n \times m$ matrix and assume that it has linearly independent columns (i.e., full column rank; remember that this implies $m \leq n$). Then the projection matrix P_X has the following properties.

1. P_X is symmetric
2. P_X is idempotent, $P_X^2 = P_X$
3. $P_X X = X$
4. $X^\top (I - P_X) = 0 \in \mathbb{R}^{m \times n}$
5. $P_X v \in \text{Im}(X)$ for all $v \in \mathbb{R}^n$
6. If $m = n$ and X is invertible, then $P_X = I$
7. $(I - P_X) v \in \text{Im}(X)^\perp$ for all $v \in \mathbb{R}^n$
8. If $w \in \text{Im}(X)$, then $P_X w = w$
9. If $w \in \text{Im}(X)^\perp$, then $P_X w = 0$
10. If Z is another $n \times m$ matrix s.t. $\text{Im}(Z) = \text{Im}(X)$, then $P_Z = P_X$. This means that P_X depends on X only through the span of its columns. Hence, for an arbitrary linear space M , we can define the projection matrix P_M onto M (an explicit form for P_M can be obtained by taking any basis of M and stacking its elements as columns in a matrix X , then forming $P_X := X (X^\top X)^{-1} X^\top$)
11. If L and M are two subspaces with $L \subseteq M$, then $P_M P_L = P_L P_M = P_L$.

Proposition 6. We have

1. $I - P_X = P_{\text{Im}(X)^\perp}$
2. if L and M are two subspaces of \mathbb{R}^n with $L \subseteq M$, then $P_M - P_L = P_{M \cap L^\perp}$

Proposition 7. Let Q be an $n \times n$ matrix of rank $m \leq n$ which is symmetric and idempotent, $Q^\top = Q, Q^2 = Q$. Then $Q = P_M$ where $M := \text{Im}(Q)$.

Proof. Exercise. □

הוכחות ברשימות השיעור.

שאלה

1. הניחו כי A מטריצה ריבועית. הוכיחו כי $IM(A^T) = Ker(A)^\perp$.
2. טענה (ללא הוכחה): מטריצה A אינה לכסינה אם"ם קיים לפחות ע"ע אחד של A , λ_i עבורו $(A - \lambda_i)^k = 0, (A - \lambda_i)^m \neq 0, \forall k \geq 2, k \geq m$. השתמשו בטענה זו והראו כי אם A מטריצה סימטרית אז היא ניתנת ללכסון.
3. השתמשו בתוצאות אלו כדי להראות כי $Q = I - P_X$ היא מטריצת הטלה למרחב המשלים האורתוגונלי של $colspace(X)$ וכתבו במפורש את הפירוק הספקטרלי של Q במונחי הו"ע של P_X .
4. הסיקו מכך ש- $\hat{\beta}_{OLS}$ הוא הממוזער של $\|Y - X\beta\|^2$ וכן שככל שדרגת X גדולה יותר, נורמה זו הולכת וקטנה.

פתרון:

1. נניח $v \in IM(A^T)$ אז $v = A^T w$ עבור $w \in R^n$. ניקח $u \in Ker(A)$. נקבל: $v^T u = w^T A u = 0$. ולכן $v \in Ker(A)^\perp$. באופן דומה מראים את ההכלה בכיוון ההפוך.
2. נניח ש- A אינה ניתנת ללכסון. בהתאם לטענה, זה קורה אם"ם קיים ע"ע λ המאפס לפחות פעמיים את הפולינום האופייני (בה"כ שני האחרונים):

$$\prod_{i=1}^n (t_i - \lambda_i) = (t_i - \lambda_n)^2 \prod_{i=1}^{n-2} (t_i - \lambda_i)$$
גם מתקיים $(A - \lambda I)v \neq 0$ (אחרת v היה ו"ע) ואילו $(A - \lambda I)^2 v = 0$.
כעת כי סימטרית: $\|v\|^2 = \|(A - \lambda I)v\|^2 = 0$. מתכונות של נורמה זה קורה אם"ם $(A - \lambda I)v = 0$ בסתירה.
3. ראשית שימו לב שזו מטריצה הטלה. מהשאלה הקודמת P_X סימטרית ולכן $IM(P_X) = Ker(P_X)^\perp$. ולהפך. כמו כן מהשאלה הקודמת, אם ניקח וקטור $v \in IM(X)$ אז $Qv \in Ker(P_X)$ וזהו המרחב המשלים האורתוגונלי ל- $IM(P_X)$. כיוון שניתנת ללכסון, לכל ו"ע u :

$$(I - P_X)u = u - \lambda u = (1 - \lambda)u$$
לכן u הוא ו"ע של Q עם ע"ע $1 - \lambda$. כאשר $\lambda \in \{0, 1\}$.
4. $\|Y - X\beta\|^2 = \|Y - P_X Y + P_X Y - X\beta\|^2 = \|Y - P_X Y\|^2 + 2|(Y - P_X Y)^T (P_X Y - X\beta)| + \|P_X Y - X\beta\|^2$
 $\|P_X Y - X\beta\|^2 \geq \|Y - P_X Y\|^2 = \|(I - P_X)Y\|^2 = \|QY\|^2$
ואם ניקח $X\hat{\beta} = P_X Y$ נקבל את החסם.

$$\|QY\|^2 = Y^T Q^2 Y = Y^T Q Y = \sum_{i=1}^{n-r} Y^T U_i U_i^T Y = \sum \|U_i^T Y\|^2$$
זהו סכום של איברים אי שליליים ולכן גדל במספר הנסכמים.

התפלגויות רב מימדיות:

- יהיו Z_1, \dots, Z_n משתנים מקריים המפולגים במשותף (ללא שום הנחות נוספות) בהתפלגות $f_{Z_1, \dots, Z_n}(z_1, \dots, z_n)$. נגדיר $Z \in R^n = (Z_1, \dots, Z_n)$ ונגדיר $E(Z) = (E[Z_1], \dots, E[Z_n])$.
- באותו האופן, אם A היא **מטריצה מקרית**, כלומר A_{ij} הוא מ"מ: $E[A] = \begin{pmatrix} E[A_{11}] & \dots & E[A_{1m}] \\ \dots & \dots & \dots \\ E[A_{n1}] & \dots & E[A_{nm}] \end{pmatrix}$
- תכונות של תוחלות של מטריצות (ובפרט וקטורים) מקריים:
- עבור Z, W מטריצות מקריות ו- A, B מטריצות קבועות, לא מקריות (דטרמיניסטיות):

1. $E[Z + W] = E[Z] + E[W]$
2. $E[AZB] = AE[Z]B$

3. $\mathbb{E}[AU + C] = A\mathbb{E}[U] + C$ (from 1+2)

עבור זוג וקטורים מקריים Z, W נגדיר את מטריצת השונות המשותפת בין Z, W :

$$\text{Cov}(Z, W) := E([Z - E(Z)][W - E(W)]^T)$$

ובאופן דומה את מטריצת השונות של הוקטור Z :

$$\text{Var}(Z) := \text{Cov}(Z, Z) := E([Z - E(Z)][Z - E(Z)]^T)$$

$$\text{Var}(Z)_{ij} = \text{cov}(Z_i, Z_j) = \text{cov}(Z_j, Z_i) = \text{Var}(Z)_{ji} \quad \text{טענה:}$$

"הוכחה":

$$\begin{aligned} \text{Var}(Z)_{ij} &= E([Z - E(Z)][Z - E(Z)]^T)_{ij} \\ &= E([Z - E(Z)]_i [Z - E(Z)]_j) = E([Z_i - E(Z_i)][Z_j - E(Z_j)]) = \text{cov}(Z_i, Z_j) \end{aligned}$$

בתרגיל תוכיחו את התכונות הבאות:

Properties of covariance matrix. $\mathbf{Z}, \mathbf{W}, \mathbf{R}$ random vectors; \mathbf{a} fixed vector. Then the following properties hold:

1. $\text{cov}(\mathbf{Z}, \mathbf{W}) = \text{cov}(\mathbf{W}, \mathbf{Z})^T$
2. $\text{cov}(\mathbf{Z} + \mathbf{R}, \mathbf{W}) = \text{cov}(\mathbf{Z}, \mathbf{W}) + \text{cov}(\mathbf{R}, \mathbf{W})$
3. $\text{cov}(\mathbf{AZ}, \mathbf{BW}) = \mathbf{A} \text{cov}(\mathbf{Z}, \mathbf{W}) \mathbf{B}^T$
4. $\text{cov}(\mathbf{AZ}) = \mathbf{A} \text{cov}(\mathbf{Z}) \mathbf{A}^T$ (from 3)
5. $V(\mathbf{a}^T \mathbf{Z}) = \mathbf{a}^T \text{cov}(\mathbf{Z}) \mathbf{a}$ (from 4)
6. $\text{cov}(\mathbf{Z})$ is a nonnegative definite matrix (from 5)

שאלה:

יהיו המשתנים המקריים הבאים: $X \sim \text{Ber}(p), Y \sim \text{Ber}(q), M := XY \sim \text{Ber}(r)$ כך שמתקיים:
 א. מצאו את וקטור התוחלות ומטריצת השונות של הוקטור המקרי $\mathbf{Z} = (X, Y, M)^T$
 ב. נגדיר את ההעתקה: $A: R^3 \rightarrow R: A(v) = 2v_1 - 3v_2 + 4v_3 + 7$. האם ההעתקה לינארית? על בסיס הסעיף הקודם חשבו את וקטור התוחלות ומטריצת השונות של $A(\mathbf{Z})$.
 ג. כעת הניחו ש- X, Y ב"ת. חשבו את ההסתברות $P(X = 1, Y = 1, M = 1)$.

פתרון:

א. עבור וקטור התוחלות אנו צריכים לחשב את התוחלת של כל אחת מ-3 הכניסות:

$$E(\mathbf{Z})^t = (E(X), E(Y), E(M))^T = (p, q, r)^T$$

בעבור מטריצת השונות: כפי שראינו, עלינו לחשב כל אחת מהשונות המשותפות:

$$\begin{aligned} \text{cov}(X, X) &= p(1 - p), \text{cov}(X, Y) = E(XY) - E(X)E(Y) = r - pq, \text{cov}(X, M) \\ &= E(X^2Y) - E(X)E(XY) = E(XY) - E(X)E(XY) = r - pr \end{aligned}$$

ובאופן דומה לשאר הכניסות.

ב. זו איננה העתקה לינארית כיוון שהוכחנו שכל העתקה לינארית מקיימת $T(0) = 0$. שימו לב שנוכל לכתוב את A כך:

$$A(v) = Bv + 7$$

עבור $B = \begin{pmatrix} 2 & -3 & 4 \end{pmatrix}$. נקבל:

$$E(AZ) = AE(Z) = \begin{pmatrix} 2 & -3 & 4 \end{pmatrix} \begin{pmatrix} p \\ q \\ r \end{pmatrix} + 7$$

$$Var(AZ) = Var(BZ) = BVar(Z)B^T = \begin{pmatrix} 2 & -3 & 4 \end{pmatrix} \begin{pmatrix} p(1-p) & r-pq & r(1-p) \\ r-pq & q(1-q) & r(1-q) \\ r(1-p) & r(1-q) & r(1-r) \end{pmatrix} \begin{pmatrix} 2 \\ -3 \\ 4 \end{pmatrix}$$

ג. במקרה כזה $r = pq = P(X=1, Y=1, M=1) = P(X=1, Y=1) = P(X=1)P(Y=1)$

יהיו $Z, W \in R^p$ וקטורים מקריים. הראו שהבאים שקולים:

$$\forall v \in R^p, Var(v^T Z) \geq Var(v^T W) \quad (1)$$

(2) $B := Var(Z) - Var(W)$ היא מטריצה חיובית למחצה.

(3) קיימת המטריצה $B^{\frac{1}{2}}$.

המודל הלינארי:

$$(X_i, Y_i), \quad i = 1, \dots, n \quad \text{נתונים:}$$

מודל לינארי:

$$Y_i = \sum_{j=0}^p \beta_j X_{ij} + \epsilon_i, \quad Cov(\epsilon_i, \epsilon_{i'}) = \begin{cases} \sigma^2, & i = i' \\ 0, & i \neq i' \end{cases}$$

כאשר $X_i = (1, X_{i1}, \dots, X_{ip})^T$ הם ממימד $p+1$,

וכאשר $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$ הם קבועים לא ידועים ו- σ^2

אפשר לקבל ייצוג קומפקטי בעזרת כתיב מטריצות. נסמן:

$$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & X_{11} & \dots & X_{1p} \\ 1 & X_{21} & \dots & X_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \dots & X_{np} \end{bmatrix}, \quad \epsilon = \begin{bmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

אז את המודל הליניארי אפשר לכתוב:

$$Y = X\beta + \epsilon, \quad \mathbb{E}[\epsilon] = \mathbf{0}, \quad \text{cov}[\epsilon] = \sigma^2 I$$

$$\hat{Y} = X\hat{\beta}, \quad e = Y - \hat{Y} \quad \text{כמו כן:}$$

(הערה: אם לא נציין אחרת, $\hat{\beta}$ זה אומד הריבועים הפחותים)

שאלה

לפניכם מספר טענות. התאימו לכל טענה האם מדובר בהנחה או בתוצאה מתמטית:

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|Y - X\beta\|^2 \quad 1.$$

$$X\beta = E(Y|X) \quad 2.$$

$$0 = E(e_i) \quad 3.$$

$$0 = E(\bar{e}) \quad 4.$$

$$X^T e = 0 \quad 5.$$

$$\text{Cov}(Y) = \sigma^2 I \quad 6.$$

פתרון:

1. תוצאה מתמטית. הראינו במספר דרכים. זהו פתרון בעיית אופטימיזציה.

2. הנחה: $Y = X\beta + \epsilon$ וכן $E(\epsilon) = EE(\epsilon|X) = E(0) = 0$

3. הנחה:

$$E(e_i) = E(Y_i - X_i^T \hat{\beta}) = E(Y_i) - E(X[X^T X]^{-1} X_i^T Y) = X_i^T \beta - X[X^T X]^{-1} X_i^T X \beta = X_i^T \beta - X_i^T \beta = 0$$

4. תוצאה: מתנאי סדר ראשון מתקבלת המשוואה הנורמלית הראשונה: $\sum_{i=1}^n e_i = 0$

$$X^T e = X^T (Y - P_X Y) = X^T (I - P_X) Y = 0$$

5. תוצאה: מצויין במפורש למעלה.

שאלה:

לפניכם מתוארים מספר מקרים. עבור כל אחד מהם פרטו את ההתפלגויות של $X, Y, Y|X, \epsilon$ וכתבו אילו הנחות של המודל הליניארי כל אחד מהם מקיים:

$$1. X_i \in R^p \text{ קבועים מראש, } Y_i = X_i^T \beta + \epsilon_i \text{ כאשר } \epsilon_i \sim N(0,1) \text{ ב"ת.}$$

$$2. X_i \in R^p \text{ מ"מ נורמליים סטנדרטיים וב"ת, } Y_i = X_i^T \beta + \epsilon_i \text{ כאשר } \epsilon_i \sim N(0,1) \text{ ב"ת.}$$

$$3. X_i \in R^1 \text{ מ"מ נורמליים סטנדרטיים וב"ת, } Y_i = X_i^2 \beta + \epsilon_i \text{ כאשר } \epsilon_i \sim U(-1,1) \text{ ב"ת.}$$

$$4. X_{it} \in R^p \text{ קבועים מראש-} \text{ כאשר } X_{itj} \text{ היא הדגימה של האדם ה- } i \text{ בתקופה ה- } t,$$

$$Y_{it} = X_{it} \beta + \epsilon_{it} \text{ כאשר } \epsilon_{it} \sim N(0,1) \text{ והנדגמים ב"ת.}$$

פתרון :

1. כל ההנחות מתקיימות.

2. כנ"ל.

3. כנ"ל. באופן כללי, נוכל להגדיר את X כמטריצת $Vandermonde$:

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix}$$

כאשר במקרה כזה האמידה של וקטור המקדמים תהיה בעצם אמידה של מקדמי פולינום.

4. כאן סביר להניח שהנחת חוסר המתאם בין $\epsilon_{it_k}, \epsilon_{it_m}$ אינה מתקיימת. דוגמה למודל שכזה :

$$Y_i = X_i\beta + \epsilon_i + \epsilon_{i+1} \cdot \mathbf{1}_{\{i \text{ is odd}\}}$$

שאלה

1. יהי $v \in R^n$, $v \neq 0$. הראו כי $\frac{vv^T}{||v||^2}$ היא מטריצת הטלה אורתוגונלית. מה דרגת המטריצה?

2. יהיו $Y_1, \dots, Y_n \sim (\mu, \sigma^2)$ מ"מ ב"ת ש"ה, כאשר שני הפרמטרים לא ידועים. הראו כי

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

3. הניחו כעת כי $Y_1, \dots, Y_n \sim N(\mu, \sigma^2)$. הוכיחו את התוצאה, שראינו בעבר

$$(n-1)S_n^2 \sim \sigma^2 \chi_{n-1}^2$$

פתרון : בתרגול הבא/תרגיל

$$\left(\frac{vv^T}{||v||^2}\right)^T = \frac{1}{||v||^2} v^T v^T = \frac{vv^T}{||v||^2} \quad 1.$$

$$\left(\frac{vv^T}{||v||^2}\right)^2 = \frac{vv^T}{||v||^2} \frac{vv^T}{||v||^2} = \frac{||v||^2}{||v||^4} vv^T = \frac{vv^T}{||v||^2}$$

דרגת המטריצה היא 1 (אפשר לדרג ולראות, או לשים לב שמדובר ב- P_X עבור $X = v$).

2. תרגיל (שפתרתם הרבה פעמים בעבר).

3. ראשית, ניתן לכתוב כל משתנה נורמלי כ- $\sigma Z_i + \mu$ עבור $Z_i \sim N(0,1)$.

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \left\| \left(I - \frac{1}{n} \cdot \mathbf{1}_n \mathbf{1}_n^T \right) Z \right\|^2 = Z^T \left(I - \frac{1}{n} \cdot \mathbf{1}_n \mathbf{1}_n^T \right) Z$$

כאשר $Z = (Z_1, \dots, Z_n)^T$, לקחנו את v מסעיף א' להיות הוקטור $\mathbf{1}_n$ וכיוון שזו מטריצת הטלה

אז גם $\left(I - \frac{1}{n} \cdot \mathbf{1}_n \mathbf{1}_n^T \right)$ המטילה למרחב המשלים שמימדו $n-1$. כמו כן סימטרית ואידימפוטנטית ומכאן המעבר האחרון. כעת כיוון שמטריצת הטלה אז ניתנת לליכסון כך שישנם

$n-1$ ע"ע שהם 1 וע"ע אחד שהוא 0. לכן ממשפט הפירוק הספקטרלי :

$$Z^T \sum_{i=1}^n \lambda_i U_i U_i^T Z = \sum_{i=1}^{n-1} (U_i^T Z)^T (U_i^T Z) = \sum_{i=1}^{n-1} (U_i^T Z)^2$$

נתבונן בהתפלגות של $U_i^T Z = \sum_j U_i^j Z_j$. זו קומבינציה לינארית של מ"מ נורמליים ולכן מתפלגת

נורמלית. התוחלת היא : $\sum_j U_i^j E(Z_j) = 0$ והשונות היא : $\sum_j U_i^j^2 = ||U_i||^2 = 1$. כלומר

התפלגות נורמלית סטנדרטית, כמו במקור. כיוון שזו פונקציה של מ"מ ב"ת אז גם הפונקציות

ב"ת. מכאן שנותרנו עם סכום ריבועים של $n-1$ מ"מ נורמליים סטנדרטיים וב"ת אשר בהגדרה

(עד שתראו זאת בהסתברות לסטטיסטיקאים) מפולגים χ^2_{n-1} .
 כעת כל שנותר הוא להכפיל ב- σ לקבל את המבוקש.

שאלה

2. נתון $Z \in \mathbb{R}^m$ וקטור מקרי. הראו כי מתקיים ש

$$\mathbb{E}(|Z|^2) = \text{tr}(\mathbb{E}[ZZ^T])$$

הסיקו מכך כי אם $\mathbb{E}[Z] = 0$ אזי מתקיים כי

$$\mathbb{E}(|Z|^2) = \text{tr}(\text{cov}[Z])$$

פרטו והצדיקו כל שלב בהוכחה.

הוכחה:

$$1. \mathbb{E}(|Z|^2) = \mathbb{E}(Z^T Z) = \mathbb{E}(\text{tr}[Z^T Z]) = \mathbb{E}(\text{tr}(ZZ^T))$$

$$2. \mathbb{E}(|Z|^2) = \text{tr}(\mathbb{E}(ZZ^T)) = \text{tr}(\mathbb{E}(Z - \mathbb{E}(Z))(\mathbb{E}(Z - \mathbb{E}(Z))^T)) = \text{tr}(\text{Cov}(Z))$$