

### התפלגויות רב מימדיות:

יהיו  $Z_1, \dots, Z_n$  משתנים מקריים המפולגים במשותף (ללא שום הנחות נוספות) בהתפלגות  $E(Z) = (E[Z_1], \dots, E[Z_n])$  וגדיר  $Z \in R^n = (Z_1, \dots, Z_n)$  נגדיר  $f_{Z_1, \dots, Z_n}(z_1, \dots, z_n)$ .  
 באותו האופן, אם  $A$  היא **מטריצה מקרית**, כלומר  $A_{ij}$  הוא מ"מ:  

$$E[A] = \begin{pmatrix} E[A_{11}] & \dots & E[A_{1m}] \\ \dots & \dots & \dots \\ E[A_{n1}] & \dots & E[A_{nm}] \end{pmatrix}$$
  
 תכונות של תוחלות של מטריצות (ובפרט וקטורים) מקריים:  
 עבור  $Z, W$  מטריצות מקריות ו- $A, B$  מטריצות קבועות, לא מקריות (דטרמיניסטיות):

1.  $E[Z + W] = E[Z] + E[W]$
2.  $E[AZB] = AE[Z]B$
3.  $E[AU + C] = AE[U] + C$  (from 1+2)

עבור זוג וקטורים מקריים  $Z, W$  נגדיר את מטריצת השונות המשותפת בין  $Z, W$ :  

$$\text{Cov}(Z, W) := E([Z - E(Z)][W - E(W)]^T)$$

ובאופן דומה את מטריצת השונות של הוקטור  $Z$ :

$$\text{Var}(Z) := \text{Cov}(Z, Z) := E([Z - E(Z)][Z - E(Z)]^T)$$

$$\text{Var}(Z)_{ij} = \text{cov}(Z_i, Z_j) = \text{cov}(Z_j, Z_i) = \text{Var}(Z)_{ji} : \text{טענה}$$

"הוכחה":

$$\begin{aligned} \text{Var}(Z)_{ij} &= E([Z - E(Z)][Z - E(Z)]^T)_{ij} \\ &= E([Z - E(Z)]_i [Z - E(Z)]_j) = E([Z_i - E(Z_i)][Z_j - E(Z_j)]) = \text{cov}(Z_i, Z_j) \end{aligned}$$

בתרגיל תוכיחו את התכונות הבאות:

*Properties of covariance matrix.*  $Z, W, R$  random vectors;  $a$  fixed vector. Then the following

properties hold:

1.  $\text{cov}(Z, W) = \text{cov}(W, Z)^T$
2.  $\text{cov}(Z + R, W) = \text{cov}(Z, W) + \text{cov}(R, W)$
3.  $\text{cov}(AZ, BW) = A \text{cov}(Z, W) B^T$
4.  $\text{cov}(AZ) = A \text{cov}(Z) A^T$  (from 3)
5.  $V(a^T Z) = a^T \text{cov}(Z) a$  (from 4)
6.  $\text{cov}(Z)$  is a nonnegative definite matrix (from 5)

### שאלה:

יהיו המשתנים המקריים הבאים:  $Z_1, \dots, Z_5 \sim N(0,1) \text{ iid.}$   
 א. מצאו את וקטור התוחלות ומטריצת השונות של הוקטור המקרי  $Z = (Z_1, \dots, Z_5)^T$ .  
 ב. נגדיר את ההעתקה:  $A: R^5 \rightarrow R^3$ :  
 $A(v) = (2v_1 - 3v_2 + 4v_3 + 7, 8v_2 - v_4 + 2v_5 + 3, 6v_3 - 1)^T$  האם ההעתקה לינארית?

על בסיס הסעיף הקודם חשבו את וקטור התוחלות ומטריצת השונויות של  $A(Z)$ .  
 ג. האם תשובתכם הייתה משתנה אילו היה ידוע כי  $Z_1, \dots, Z_5$  היו נדגמים כך ש-  $Z_i \sim \text{unif}(-\sqrt{3}, \sqrt{3})$ ?  
 פתרון:

א. עבור וקטור התוחלות אנו צריכים לחשב את התוחלת של כל אחת מ-5 הכניסות:

$$E(Z)^t = (E(Z_1), \dots, E(Z_5))^T = (0, \dots, 0)^T$$

בעבור מטריצת השונויות: כפי שראינו, עלינו לחשב כל אחת מהשונויות המשותפות:

$$\text{Cov}(Z_i, Z_j) = 0, \forall i \neq j$$

$$\text{Cov}(Z_i, Z_i) = \text{Var}(Z_i) = 1, \forall i$$

ב. זו איננה העתקה לינארית כיוון שהוכחנו שכל העתקה לינארית מקיימת  $T(0) = 0$ . שימו לב שנוכל לכתוב את  $A$  כך:

$$A(v) = Bv + (7, 3, -1)^T := Bv + \mu$$

$$B = \begin{pmatrix} 2 & -3 & 4 & 0 & 0 \\ 0 & 8 & 0 & -1 & 2 \\ 0 & 0 & 6 & 0 & 0 \end{pmatrix}$$

$$E(AZ) = BE(Z) + \mu = \mu$$

$$\text{cov}(AZ) = \text{cov}(BZ + \mu) = \text{cov}(BZ) = B\text{cov}(Z)B^T = BIB^T = BB^T$$

יהיו  $Z, W \in R^p$  וקטורים מקריים. הראו שהבאים שקולים:

$$\forall v \in R^p, \text{Var}(v^T Z) \geq \text{Var}(v^T W) \quad (1)$$

$$B := \text{Var}(Z) - \text{Var}(W) \text{ היא מטריצה חיובית למחצה.} \quad (2)$$

$$(3) \text{ קיימת המטריצה } B^{\frac{1}{2}}.$$

הוכחה: תרגיל.

המודל הלינארי:

$$(X_i, Y_i), \quad i = 1, \dots, n$$

מודל לינארי:

$$Y_i = \sum_{j=0}^p \beta_j X_{ij} + \epsilon_i, \quad \text{Cov}(\epsilon_i, \epsilon_{i'}) = \begin{cases} \sigma^2, & i = i' \\ 0, & i \neq i' \end{cases}$$

$$X_i = (1, X_{i1}, \dots, X_{ip})^T \text{ כאשר } p+1 \text{ הם ממיד } p$$

$$\beta = (\beta_0, \beta_1, \dots, \beta_p)^T \text{ ו-}\sigma^2 \text{ הם קבועים לא ידועים}$$

אפשר לקבל ייצוג קומפקטי בעזרת כתיב מטריצות. נסמן:

$$Y = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & X_{11} & \dots & X_{1p} \\ 1 & X_{21} & \dots & X_{2p} \\ \vdots & \vdots & & \vdots \\ 1 & X_{n1} & \dots & X_{np} \end{bmatrix}, \quad \epsilon = \begin{bmatrix} \epsilon_1 \\ \vdots \\ \epsilon_n \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}$$

אז את המודל הליניארי אפשר לכתוב:

$$Y = X\beta + \epsilon, \quad \mathbb{E}[\epsilon] = \mathbf{0}, \quad \text{cov}[\epsilon] = \sigma^2 I$$

$$\hat{Y} = X\hat{\beta}, \quad e = Y - \hat{Y} \quad \text{כמו כן:}$$

(הערה: אם לא נציין אחרת,  $\hat{\beta}$  זה אומד הריבועים הפחותים)

### שאלה

לפניכם מספר טענות. התאימו לכל טענה האם מדובר בהנחה או בתוצאה מתמטית:

1.  $\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|Y - X\beta\|^2$
2.  $X\beta = E(Y|X)$
3.  $0 = E(e_i)$
4.  $0 = E(\bar{e})$  (עבור רגרסיה עם חותך).
5.  $X^T e = 0$
6.  $\text{Cov}(Y) = \sigma^2 I$

פתרון:

1. תוצאה מתמטית. הראינו במספר דרכים. זהו פתרון בעיית אופטימיזציה.
2. הנחה:  $Y = X\beta + \epsilon$  וכן  $E(\epsilon) = EE(\epsilon|X) = E(0) = 0$ .
3. הנחה:
4. תוצאה: מתנאי סדר ראשון מתקבלת המשוואה הנורמלית הראשונה:  $\sum_{i=1}^n e_i = 0$ . דרך נוספת:

$$\sum_{i=1}^n e_i = \sum_{i=1}^n Y_i - \hat{Y}_i = \sum_{i=1}^n (I - P_X)Y = 1_n^T (I - P_X)Y = 1_n^T (I - P_X)^T Y = ((I - P_X)1_n)^T Y = 0^T Y = 0$$

וזאת כיוון שברגרסיה עם חותך, עמודת האחדות שייכת ל  $IM(X)$ .

5. תוצאה:  $X^T e = X^T (Y - P_X Y) = X^T (I - P_X)Y = 0$ .

6. הנחה:  $\text{cov}(Y) = \text{cov}(X\beta + \epsilon) = \text{cov}(\epsilon) = \sigma^2 I$ .

וכאן השתמשנו בהנחת הליניאריות במעבר הראשון ובשיוויון השוניות במעבר האחרון.

## שאלה:

לפניכם מתוארים מספר מקרים. עבור כל אחד מהם פרטו את ההתפלגויות של  $X, Y, Y|X, \epsilon$  וכתבו אילו הנחות של המודל הלינארי כל אחד מהם מקיים:

1.  $X_i \in R^p$  קבועים מראש,  $Y_i = X_i^T \beta + \epsilon_i$  כאשר  $\epsilon_i \sim N(0,1)$  ב"ת.
2.  $X_i \in R^p$  מ"מ נורמליים סטנדרטיים וב"ת,  $Y_i = X_i^T \beta + \epsilon_i$  כאשר  $\epsilon_i \sim N(0,1)$  ב"ת.
3.  $X_i \in R^1$  מ"מ נורמליים סטנדרטיים וב"ת,  $Y_i = X_i^2 \beta + \epsilon_i$  כאשר  $\epsilon_i \sim U(-1,1)$  ב"ת.
4.  $X_{it} \in R^p$  קבועים מראש- כאשר  $X_{itj}$  היא הדגימה של האדם ה-  $i$  בתקופה ה-  $t$ ,  $Y_{it} = X_{it}^T \beta + \epsilon_{it}$  כאשר  $\epsilon_{it} \sim N(0,1)$  והנדגמים ב"ת.

## פתרון:

1. כל ההנחות מתקיימות.
2. כנ"ל.
3. כנ"ל. באופן כללי, נוכל להגדיר את  $X$  כמטריצת  $Vandermonde$ : בה האיבר ה-  $ij$  הוא  $X_i^{j-1}$  כאשר במקרה כזה האמידה של וקטור המקדמים תהיה בעצם אמידה של מקדמי פולינום.
4. כאן סביר להניח שהנחת חוסר המתאם בין  $\epsilon_{it_k}, \epsilon_{it_m}$  אינה מתקיימת. דוגמה למודל שכזה:  

$$Y_i = X_i \beta + \epsilon_i + \epsilon_{i+1} \cdot \mathbf{1}_{\{i \text{ is odd}\}}$$

## שאלה

1. יהי  $v \in R^n, v \neq 0$ . הראו כי  $\frac{vv^T}{||v||^2}$  היא מטריצת הטלה אורתוגונלית. מה דרגת המטריצה?
2. יהיו  $Y_1, \dots, Y_n \sim (\mu, \sigma^2)$  מ"מ ב"ת ש"ה, כאשר שני הפרמטרים לא ידועים. הראו כי  $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2$  הוא אומד ח"ה ל- $\sigma^2$ .
3. הניחו כעת כי  $Y_1, \dots, Y_n \sim N(\mu, \sigma^2)$ . הוכיחו את התוצאה, שראינו בעבר  $(n-1)S_n^2 \sim \sigma^2 \chi_{n-1}^2$ .

## פתרון:

$$\left( \frac{vv^T}{||v||^2} \right)^T = \frac{1}{||v||^2} v^T v^T = \frac{vv^T}{||v||^2} \quad 1.$$

$$\left( \frac{vv^T}{||v||^2} \right)^2 = \frac{vv^T}{||v||^2} \frac{vv^T}{||v||^2} = \frac{||v||^2}{||v||^4} vv^T = \frac{vv^T}{||v||^2}$$

1. דרגת המטריצה היא 1 (אפשר לדרג ולראות, או לשים לב שמדובר ב- $P_X$  עבור  $v = X$ ).
2. תרגיל (שפתרתם הרבה פעמים בעבר).
3. ראשית, ניתן לכתוב כל משתנה נורמלי כ- $\sigma Z_i + \mu$  עבור  $Z_i \sim N(0,1)$ .

$$\sum_{i=1}^n (Z_i - \bar{Z})^2 = \left\| \left( I - \frac{1}{n} \cdot \mathbf{1}_n \mathbf{1}_n^T \right) Z \right\|^2 = Z^T \left( I - \frac{1}{n} \cdot \mathbf{1}_n \mathbf{1}_n^T \right) Z$$

כאשר  $Z = (Z_1, \dots, Z_n)^T$ , לקחנו את  $v$  מסעיף א' להיות הוקטור  $\mathbf{1}_n$  וכיוון שזו מטריצת הטלה אז גם  $\left( I - \frac{1}{n} \cdot \mathbf{1}_n \mathbf{1}_n^T \right)$  המטילה למרחב המשלים שמימדו  $n-1$ . כמו כן סימטרית ואידימפוטנטית ומכאן המעבר האחרון. כעת כיוון שמטריצת הטלה אז ניתנת לליכסון כך שישנם  $n-1$  ע"ע שהם 1 וע"ע אחד שהוא 0. לכן ממשפט הפירוק הספקטרלי:

$$Z^T \sum_{i=1}^n \lambda_i U_i U_i^T Z = \sum_{i=1}^{n-1} (U_i^T Z)^T (U_i^T Z) = \sum_{i=1}^{n-1} (U_i^T Z)^2$$

נתבונן בהתפלגות של  $U_i^T Z = \sum_j U_i^j Z_j$ . זו קומבינציה לינארית של מ"מ נורמליים ולכן מתפלגת נורמלית. התוחלת היא:  $\sum_j U_i^j E(Z_j) = 0$  והשונות היא:  $\sum_j U_i^j^2 = \|U_i\|^2 = 1$ . כלומר התפלגות נורמלית סטנדרטית, כמו במקור. כיוון שזו פונקציה של מ"מ ב"ת אז גם הפונקציות ב"ת. מכאן שנותרנו עם סכום ריבועים של  $n - 1$  מ"מ נורמליים סטנדרטיים וב"ת אשר בהגדרה (עד שתראו זאת בהסתברות לסטטיסטיקאים) מפולגים  $\chi_{n-1}^2$ . כעת כל שנותר הוא להכפיל ב- $\sigma$  לקבל את המבוקש.

## שאלה

2. נתון  $Z \in \mathbb{R}^m$  וקטור מקרי. הראו כי מתקיים ש

$$\mathbb{E}(\|Z\|^2) = \text{tr}(\mathbb{E}[ZZ^T])$$

הסיקו מכך כי אם  $\mathbb{E}[Z] = 0$  אזי מתקיים כי

$$\mathbb{E}(\|Z\|^2) = \text{tr}(\text{cov}[Z])$$

פרטו והצדיקו כל שלב בהוכחה.

2 הוכיחו כי עבור  $U, V$  וקטורים מקריים שידוע שהתוחלת של לפחות אחד מהם היא וקטור ה-0, מתקיים:

$$E(U^T V) = \text{tr}(\text{cov}(VU^T))$$

הוכחה:

$$1. E(\|Z\|^2) = E(Z^T Z) = E(\text{tr}[Z^T Z]) = E(\text{tr}(ZZ^T)).$$

$$2. E(\|Z\|^2) = \text{tr}(E(ZZ^T)) = \text{tr}(E(Z - E(Z))(E(Z - E(Z))^T)) = \text{tr}(\text{Cov}(Z)).$$

## שאלה - מועד א' תשפ"ד

הניחו שהנחות המודל הלינארי מתקיימות.

ד. (15 נק') נסמן  $M := \text{Im}(X)$ . נסמן ב- $\tilde{X}$  את המטריצה המתקבלת מ- $X$  ע"י מחיקת חלק מהעמודות, ונסמן  $L := \text{Im}(\tilde{X})$ . הראו שמתקיים  $P_L Y = P_L \hat{Y}$  (כאשר  $\hat{Y}$  זה וקטור הערכים החזויים במודל עם מטריצת ה- $X$  המקורית). האם נדרשות הנחות המודל הלינארי או המודל הלינארי הנורמלי כדי שהטענה תתקיים?

$$ב. מצאו את  $E(\|e\|^2)$$$

ב. (10 נק') חשבו את הגדלים הבאים, וציינו את המימד שלהם:  $\text{cov}(\hat{\beta}, e)$ ,  $\text{cov}(e, e)$ ,  $\text{cov}(e)$ .

ג. מצאו את  $\text{cov}(Y_i, \hat{Y}_i)$ .

פתרון:

1. ראינו כי לכל  $L, M$  תתי מרחבים כך ש- $L \subseteq M$  מתקיים  $P_M P_L = P_L P_M = P_L$  שכן (תזכורת להוכחה- אפשר היה פשוט לצטט את המשפט):

$$\begin{aligned} \forall v \in R^n, \quad P_M P_L v &= P_L v \text{ since } P_L v \in M \\ \Rightarrow P_L P_M v &= P_L^T P_M^T v = (P_M P_L)^T v = P_L^T v = P_L v \end{aligned}$$

ואז:

$$P_L \hat{Y} = P_L P_M Y = P_L Y$$

רק נותר להראות  $IM(\tilde{X}) \subseteq IM(X)$ : נניח בה"כ שמדובר ב- $m < p$  העמודות האחרונות. אז לכל  $w \in IM(\tilde{X}) \Rightarrow w = \sum_{i=1}^{p+1-m} X^i k_i = \sum_{i=1}^{p+1-m} X^i k_i + \sum_{i=p-m}^{p+1} X^i \cdot 0 \Rightarrow w \in IM(X)$   
כל אלו נכונות ללא שום הנחה.

2.

$$E(e) = E(Y - \hat{Y}) = E(Y) - E(P_X Y) = X\beta - P_X X\beta = 0$$

כאשר השתמשנו בהנחת הליניאריות ובכך ש- $P_X X = X$ .  
נפעיל את הטענה מהשאלה הקודמת ונקבל:

$$\begin{aligned} E(||e||^2) &= tr(cov(e)) = tr(cov((I - P_X)Y)) = tr((I - P_X)cov(Y)(I - P_X)^T) \\ &= tr(\sigma^2(I - P_X)(I - P_X)^T) = tr(\sigma^2(I - P_X)) = \sigma^2 \cdot rank(I - P_X) \\ &= \sigma^2 \cdot (n - p - 1) \end{aligned}$$

3. תרגיל

שאלה- בוחן אמצע תשפ"ב

נתון מודל ליניארי,  $Y = X\beta + \varepsilon$ , כאשר  $\varepsilon \sim (0, \sigma^2 I_n)$ .

עבור  $u, v \in \mathbb{R}^n$  כלשהם נגדיר את נורמת מהלנוביס (Mahalanobis) באופן הבא:

$$||u - v||_{\Sigma} = \sqrt{(u - v)^T \Sigma^{-1} (u - v)}$$

כאשר  $\Sigma \in \mathbb{R}^{n \times n}$  מטריצה סימטרית חיובית.

כמו כן נגדיר את  $\hat{\beta}^{\Sigma}$  באופן הבא:

$$\hat{\beta}^{\Sigma} = \underset{\beta \in \mathbb{R}^{p+1}}{\operatorname{argmin}} ||Y - X\beta||_{\Sigma}^2$$

א. הראו שמתקיים

$$\hat{\beta}^{\Sigma} = (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} Y$$

והסבירו את האומד שמתקבל במקרה  $\Sigma = I_n$ .

**הדרכה:** אפשר (לא חייב ש) להעזר בעובדה הבאה:  $A \in \mathbb{R}^{m \times m}$  מטריצה סימטרית חיובית, אזי קיימת מטריצה  $B \in \mathbb{R}^{m \times m}$  סימטרית חיובית כך ש:  $B^T B = A$ . ניתן להפעיל מסקנה זו על  $\Sigma$  כך שיהיה ניתן לייצג את  $\Sigma^{-1}$  באופן הבא:  $\Sigma^{-1} = C^T C$  עבור מטריצה  $C$  ריבועית כלשהי. מצאו מי היא  $C$ , הסבירו מדוע היא מוגדרת היטב, ואז הגדירו משתנים חדשים

$\tilde{Y} = CY$ ,  $\tilde{X} = CX$  ופתרו את הבעיה (שימו לב שעבור ה  $C$  הנכון הפתרון מייד, חישובו מדוע).

ב. הראו כי  $\hat{\beta}^\Sigma$  הינו אומד חסר הטיה ל  $\beta$ , וכן מצאו את  $cov(\hat{\beta}^\Sigma)$ .

פתרון: תרגיל.