

תזכורת

פונקציית סיכון MSE :

יהי θ פרמטר לא ידוע ו- $\hat{\theta}$ אומד ל- $\theta \in \Theta$. נגדיר את פונקציית ה- $MSE(\theta, \hat{\theta})$:

$$E(\hat{\theta} - \theta)^2 = Var(\hat{\theta}) + E^2(\hat{\theta} - \theta)$$

ובאופן כללי עבור $\theta \in \Theta \subseteq R^p$:

$$MSE(\hat{\theta}, \theta) = E \left\| \hat{\theta} - \theta \right\|^2$$

נאמר כי אומד $\hat{\theta}$ טוב יותר מאומד $\tilde{\theta}$ אם מתקיים שלכל $\theta \in \Theta$:

$$MSE(\theta, \tilde{\theta}) \geq MSE(\theta, \hat{\theta})$$

וקיים לפחות θ' אחד עבורו אי השוויון חזק.

שאלה:

הראו כי במקרה הרב מימדי:

$$MSE(\hat{\theta}, \theta) = E \left\| \hat{\theta} - \theta \right\|^2 = tr[Var(\hat{\theta})] + \left\| E(\hat{\theta}) - \theta \right\|^2$$

פתרון:

$$\begin{aligned} E \left\| \hat{\theta} - \theta \right\|^2 &= E \left\| \hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta \right\|^2 \\ &= E \left\| \hat{\theta} - E(\hat{\theta}) \right\|^2 + 2E \left[\left(\hat{\theta} - E(\hat{\theta}) \right)^T (E(\hat{\theta}) - \theta) \right] + E \left\| E(\hat{\theta}) - \theta \right\|^2 \end{aligned}$$

הביטוי הימני ביותר דטרמיניסטי ולכן שווה לתוחלתו. באשר לביטוי האמצעי- $(E(\hat{\theta}) - \theta)$ גם כן דטרמיניסטי ולכן ניתן להוציאו מהתוחלת. נקבל:

$$E \left[\left(\hat{\theta} - E(\hat{\theta}) \right)^T (E(\hat{\theta}) - \theta) \right] = (E[\hat{\theta} - E(\hat{\theta})])^T (E(\hat{\theta}) - \theta) = 0^T (E(\hat{\theta}) - \theta) = 0$$

כעת, בעבור הביטוי השמאלי, נשים לב שהמשתנה $\hat{\theta} - E(\hat{\theta})$ הוא מ"מ עם תוחלת 0. נשתמש בטענה מתרגול 3:

הסיקו מכך כי אם $E[Z] = 0$ אזי מתקיים כי

$$E \left(\left\| Z \right\|^2 \right) = tr(cov[Z])$$

ונסיק כי:

$$E \left\| \hat{\theta} - E(\hat{\theta}) \right\|^2 = tr \left(Var \left(\hat{\theta} - E(\hat{\theta}) \right) \right) = tr \left(Var(\hat{\theta}) \right)$$

שמשלים את ההוכחה.

משפט גאוס-מרקוב (אומד OLS הוא $BLUE$)

תהי $a^T \beta := \theta$. נסמן את אומד OLS ל- θ : $c^T Y := a^T \hat{\beta} := \hat{\theta}$ עבור $c = X(X^T X)^{-1} a$. זהו אומד לינארי ב- Y חסר הטיה ל- θ . נסמן ב- $d^T Y$ אומד חסר הטיה אחר שגם הוא לינארי ב- Y . אז מתקיים שלכל θ :

$$Var(d^T Y, \theta) \geq Var(c^T Y, \theta) \Rightarrow MSE(d^T Y, \theta) \geq MSE(c^T Y, \theta)$$

שאלה- לא צריכים לדעת להוכיח בעצמכם כרגע

הראו כי אומד ה-BLUE הינו יחיד :

נניח שרוצים לאמוד את הקומבינציה הלינארית $a^T \beta := \theta$, תוך שימוש באומדים לינאריים בוקטור Y . נגדיר $a^T \hat{\beta}_{OLS} = c^T Y$.
נניח שקיים אומד לינארי ב- Y אחר וח"ה עם שונות זהה לשל אומד OLS . נסמנו ב- $d^T Y$, אז הצירוף:
$$T = 0.5c^T Y + 0.5d^T Y = 0.5(c + d)^T Y$$

גם הוא לינארי וחסר הטיה. נחשב את השונות שלו:

תזכורת: לכל זוג משתנים X_1, X_2 מתקיים:

$$Cov(X_1, X_2) \leq \sqrt{Var(X_1)Var(X_2)}$$

לכן:

$$\begin{aligned} Var(T) &= 0.25Var(c^T Y) + 0.25Var(d^T Y) + 0.5 \cdot cov(c^T Y, d^T Y) \\ &\leq 0.25Var(c^T Y) + 0.25Var(d^T Y) + 0.5 \cdot var(c^T Y) = var(c^T Y) \end{aligned}$$

כיוון שהראינו ש- $c^T Y$ הוא האומד הלינארי חסר ההטיה בעל השונות הנמוכה ביותר, מתחייב שאי השיוויון מתקיים בשיוויון. ובפרט קיבלנו כי $cov(c^T Y, d^T Y) = var(c^T Y)$

כעת נסתכל על ההפרש $c^T Y - d^T Y$. זהו משתנה מקרי (כי Y מקרי) בעל תוחלת 0 (כי שני האומדים חסרי הטיה). נקבל:

$$var(c^T Y - d^T Y) = (c - d)^T Var(Y)(c - d) = \sigma^2 \|c - d\|^2$$

מצד שני,

$$var(c^T Y - d^T Y) = var(c^T Y) + var(d^T Y) - 2cov(c^T Y, d^T Y) = 2var(c^T Y) - 2var(c^T Y) = 0$$

לכן מתכונות של נורמה וחיוביות השונות של Y , בהכרח מתקיים $c = d$.

שאלה

3 רגולריזציות לרגרסיית ריבועים פחותים (Ridge & Lasso)

Ridge

$$\hat{\beta}_{\text{Ridge}} = \arg \min_{\beta} \|X\beta - y\|_2^2 + \lambda_{\text{Ridge}} \|\beta\|_2^2$$

הניחו מודל לינארי $Y = X\beta + \varepsilon$, עבור $E[\varepsilon] = 0$, $Cov(\varepsilon) = \sigma^2 I$.

אומד רכס (ridge) עבור $c > 0$ כלשהו מוגדר בצורה הבאה:

$$\hat{\beta}_{\text{ridge}} = (X'X + cI)^{-1} X'Y$$

נסמן ב- $UDU' = X'X$ את הפירוק הספקטרלי של $X'X$, כאשר $D = \text{diag}(d_1, \dots, d_p)$ הם הערכים העצמיים.

(א) מצאו ביטוי עבור התוחלת של $\hat{\beta}_{\text{ridge}}$.

(ב) בטאו את השונות המשותפת של $\hat{\beta}_{\text{ridge}}$ בעזרת $\sigma^2, c, d_1, \dots, d_p, U$.

(ג) הוכיחו שלכל וקטור קבוע $a \in R^p, a \neq 0$ מתקיים $Var(a'\hat{\beta}_{\text{ridge}}) < Var(a'\hat{\beta}_{OLS})$,

והסבירו כיצד התכונה מתיישבת עם משפט גאוס-מרקוב. (כלומר משפט ה"אומד BLUE").

התפלגות רב נורמלית

נגיד שוקטור מקרי $W \in \mathbb{R}^m$ מפולג רב-נורמלי מממד m ניתן לכתוב את W :

$$W = \mu + AZ$$

עבור $Z = (Z_1, \dots, Z_d), Z_i \sim N(0,1), iid's$ כאשר $Z \in \mathbb{R}^d, \mu \in \mathbb{R}^m, A \in \mathbb{R}^{m \times d}$

ונסמן $W \sim N(\mu, AA^T)$.

אם המטריצה $AA^T := V$ הפיכה אז קיימת צפיפות והיא מוגדרת על ידי:

$$f_W(w) = (2\pi)^{-m/2} |V|^{-1/2} \exp \left[-(\mathbf{w} - \mu)^T V^{-1} (\mathbf{w} - \mu) / 2 \right], \quad \mathbf{w} \in \mathbb{R}^m$$

א. הראו כי אם ל- W קיימת צפיפות, אז:

$$\mathbf{c}^T W \sim \mathcal{N}(\mathbf{c}^T \mu, \mathbf{c}^T V \mathbf{c}) \quad \forall \mathbf{c} \in \mathbb{R}^m \iff W \sim \mathcal{N}_m(\mu, V).$$

ב. מצאו את ההתפלגות השולית של הכניסה j -ה של W_j .
ג. הכלילו את התוצאה למציאת ההתפלגות של:

$$\text{If } C \in \mathbb{R}^{m \times k} \text{ constant matrix then } CW \sim \mathcal{N}_m(C\mu, CVC^T).$$

א. נוכיח בעבור המקרה הכללי של סעיף ג'. נתבונן בוקטור המקרי:

$$CW = C\mu + CAZ$$

נסמן ב- $\tilde{\mu} := C\mu \in \mathbb{R}^m$ וכן $\tilde{A} := CA \in \mathbb{R}^{m \times k}$:

$$CW = \tilde{W} = \tilde{\mu} + \tilde{A}Z$$

בעבור אותו הוקטור Z שכניסותיו מ"מ נורמליים סטנדרטיים ב"ת ולכן רב נורמלי m מימדי. בפרט זה קורה כאשר $m = 1$ במקרה של סעיף א. כלומר- טרנספורמציה לינארית של מ"מ נורמליים, מפולגת גם היא נורמלית. התוחלת והשונות מידיים.

מצד שני: אם לכל $c \in \mathbb{R}$ מתקיים ש- $c^T W$ מפולג נורמלי עם הפרמטרים לעיל, אז הפונקציה יוצרת המומנטים של $c^T W$:

$$M_{CW}(s) = E(e^{(Cs)^T W}) = e^{s^T C^T \mu} e^{s^T C^T V C s}, \forall c \in \mathbb{R}^{m \times k}$$

נסמן $Cs =: \tilde{s}$ ונקבל:

$$e^{s^T C^T \mu} e^{s^T C^T V C s} = e^{\tilde{s}^T \mu} e^{\tilde{s}^T V \tilde{s}} = M_W(\tilde{s})$$

בעבור W המפולג כמו בטענה. כיוון שפיי"מ מגדירה באופן יחיד את ההתפלגות, מתקבלת הטענה.

ב. כדי למצוא את ההתפלגות השולית של W_j נוכל לקחת $c = e_j \in \mathbb{R}^m$. שימו לב שנקבל מכך את המשתנה W_j . לפי הטענה מהסעיף הקודם, נקבל שההתפלגות של $c^T W$ היא נורמלית חד מימדית. התוחלת של המ"מ היא $e_j^T \mu = \mu_j$ והשונות היא $e_j^T V e_j = V_{jj}$.

ג. וכן במקרה הרב מימדי:

כאשר ההוכחות מבוססות על כך שניתן להסתכל על המשתנה החדש :

$$CW = C\mu + CAZ = \tilde{\mu} + \tilde{A}Z$$

מצד שני, אם לכל $c \in R$ מתקיים ש- $c^T W$ מפולג נורמלי עם הפרמטרים לעיל, אז הפונקציה יוצרת המומנטים של $c^T W$:

$$M_{c^T W}(s) = E(e^{sc^T W}) = e^{sc^T \mu} e^{s^2 c^T V c}, \forall c \in R^m$$

נסמן $\tilde{s} = sc$ ונקבל :

$$e^{sc^T \mu} e^{s^2 c^T V c} = e^{\tilde{s}^T \mu} e^{\tilde{s}^T V \tilde{s}} = M_W(\tilde{s})$$

בעבור W המפולג כמו בטענה. כיוון שפיי"מ מגדירה באופן יחיד את ההתפלגות, מתקבלת הטענה.

הערה: לא צריכים לדעת להוכיח את הטענות שמשתמשות בפונקציה יוצרת מומנטים - אלא רק צד אחד. ראו הקלטה.

בשאלה זו נראה שעבור התפלגות דו-נורמלית, אי-תלות שקולה לחוסר קורלציה. עבור

$$X = (X_1, X_2)^T \sim N(\mu, \Sigma)$$

א. הראו שאם X_1 ו- X_2 בלתי תלויים אזי $Cov(X_1, X_2) = 0$, כלומר Σ מטריצה אלכסונית.

ב. הראו שאם Σ מטריצה אלכסונית אזי X_1 ו- X_2 בלתי תלויים.

פתרון:

א. זה נכון לכל זוג מ"מ ב"ת:

$$\begin{aligned} E(X_1 X_2) &= \int \int x_1 x_2 f_{X_1, X_2}(x_1, x_2) dx_1 dx_2 = \int \int x_1 x_2 f_{X_1}(x_1) \cdot f_{X_2}(x_2) dx_1 dx_2 \\ &= \int x_2 f_{X_2}(x_2) dx_2 \int x_1 f_{X_1}(x_1) dx_1 = E(X_2) E(X_1) \end{aligned}$$

ב. אם Σ אלכסונית (ונניח כי בעלי צפיפות):

$$\begin{aligned} f_{\vec{X}}(\vec{x}) &= (2\pi)^{-\frac{n}{2}} \cdot |\Sigma|^{-\frac{1}{2}} \cdot e^{-\frac{1}{2}(\vec{x}-\mu)^T \Sigma^{-1}(\vec{x}-\mu)} = (2\pi)^{\frac{n}{2}} \cdot (\prod_{i=1}^n \Sigma_{ii})^{-\frac{1}{2}} \cdot e^{-\frac{1}{2} \sum_{i=1}^n (x_i - \mu_i)^T \Sigma_{ii}^{-1} (x_i - \mu_i)} \\ &= \prod_{i=1}^n (2\pi \Sigma_{ii})^{-\frac{1}{2}} e^{-\frac{(x_i - \mu_i)^2}{2 \Sigma_{ii}}} \end{aligned}$$

כלומר הצפיפות המשותפת מתפרקת למכפלת צפיפויות רב נורמליות חד מימדיות ולכן ב"ת.

שאלה- דוגמה מספרית

נתונים 4 משתנים מקריים Y_1, Y_2, Y_3, Y_4 בעלי תוחלת 0 ושונויות משותפת המקיימת $Cov(Y_i, Y_j) = \min(i, j)$ לכל $1 \leq i, j \leq 4$. ההתפלגות המשותפת של 4 המשתנים היא רב נורמלית. נגדיר $S = Y_1 + Y_2 + Y_3 + Y_4$.

(א) זהו באופן מפורש את ההתפלגות של S .

פתרון:

נמצא את ההתפלגות של $S = \sum_{i=1}^4 Y_i$

$$S = \sum_{i=1}^4 Y_i = \begin{pmatrix} 1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ Y_4 \end{pmatrix}$$

$$\text{ונסמן } 1_4 = \begin{pmatrix} 1 & 1 & 1 & 1 \end{pmatrix} \text{ נתון כי } \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ Y_4 \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 2 \\ 1 & 2 & 3 & 3 \\ 1 & 2 & 3 & 4 \end{pmatrix} \right)$$

$$S \sim N \left(\begin{pmatrix} 1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 1 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 2 \\ 1 & 2 & 3 & 3 \\ 1 & 2 & 3 & 4 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \right)$$

כלומר,

$$S \sim N(0, 30)$$

התפלגויות קשורות להתפלגות הנורמלית ומבוא להסקה סטטיסטית

Definition (Chi-square distribution). If $Z_1, Z_2, \dots, Z_k \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 1)$, then the distribution of

$$Q = \sum_{j=1}^k Z_j^2$$

is called the Chi-square distribution with k degrees of freedom, and we denote $Q \sim \chi_k^2$ (in R: `pchisq()`, `qchisq()`, `rchisq()`).

Definition 5 (t -distribution). . If $Z \sim \mathcal{N}(0, 1)$, $V \sim \chi_k^2$, are independent random variables, then the distribution of

$$T = \frac{Z}{\sqrt{V/k}}$$

is called the t -distribution with k degrees of freedom, and we denote $T \sim t_k$ (in R: `pt()`, `qt()`, `rt()`).

Definition 6 (F distribution). If $V_1 \sim \chi_{k_1}^2$, $V_2 \sim \chi_{k_2}^2$, are independent random variables, the distribution of

$$F = \frac{V_1/k_1}{V_2/k_2}$$

is called the F -distribution with k_1 and k_2 (numerator and denominator, respectively) degrees of freedom, and we denote $F \sim F_{k_1, k_2}$.

שאלה

חימום: הראו שאם $T \sim t_k$ או $T^2 \sim F_{1,k}$.

א. הראו כי $\widehat{\sigma^2} = \frac{\|e\|^2}{n-p-1}$ הוא אומד חסר הטיות ל- σ^2 .

ב. הראו שאם P מטריצת הטלה מדרגה r , ואם $Z \sim N(0, I)$ אז מתקיים:

$$\|PZ\|^2 \sim \chi_r^2$$

ג. הסיקו כי תחת הנחת הנורמליות מתקיים: $\|e\|^2 = \|Y - \hat{Y}\|^2 \sim \sigma^2 \chi_{n-p-1}^2$

ד. יהי $Z \sim N_q(\mu, \Sigma)$ כלומר $Z \in \mathbb{R}^q$ מתפלג רב-נורמלית עם וקטור תוחלות μ ומטריצת שוניות משותפות Σ . הראו כי

$$(Z - \mu)^T \Sigma^{-1} (Z - \mu) \sim \chi_q^2$$

ה. יהי $Y \sim N_n(X\beta, \sigma^2 I_q)$

ו. הראו כי המשתנים $\|Y\|^2$ ו- $\|e\|^2$ ביית.

ז. אפינו את ההתפלגות של

$$\frac{\|\hat{Y} - X\beta\|^2}{\|e\|^2}$$

ז. נסמן ב- $s_j = (X^T X)^{-1}_{jj}$. אפינו את ההתפלגות של $(\hat{\beta}_j - \beta_j) / \sqrt{\widehat{\sigma^2} s_j}$.

פתרון:

אם $T \sim t_k$ אז $T = \frac{Z}{\sqrt{V/k}}$ בעבור $Z \sim N(0,1)$ ו- $V \sim \chi_k^2$ ביית. מכאן ש- $T^2 = \frac{Z^2}{V/k}$. המונה מפולג χ_1^2

ולכן גם בחלוקה ב-1 והמכנה הוא χ_k^2 מחולק בדרגות החופש שלו. זו בדיוק ההגדרה של התפלגות $F_{1,k}$.

א. ראשית נסתכל על:

$$E(e) = E[(I - P_X)Y] = (I - P_X)X\beta = 0$$

בתרגול 3 ראינו כי בעבור וקטור מקרי עם תוחלת 0 מתקיים:

$$E(\|e\|^2) = \text{tr}(\text{Var}(e))$$

צד ימין שווה במקרה הזה:

$$\text{tr}(\text{Var}(I - P_X)Y) = \text{tr}(\sigma^2(I - P_X)(I - P_X)^T) = \sigma^2 \text{tr}((I - P_X))$$

כאשר השיוון האחרון נכון כי זו מטריצת הטלה ולכן סימטרית ואיידמפוטנטית. כעת נשתמש בתכונה נוספת של מטריצת הטלה מתרגיל 2 שאומרת ש- $\text{rank}(I - P_X) = \text{tr}(I - P_X)$, וכן בעובדה ש- $I - P_X$ מטילה למרחב ממימד $n - (p + 1)$ ונקבל כי $E(\|e\|^2) = \sigma^2(n - p - 1)$. נחלק בגורם המתאים ונקבל את הטענה.

ב.

$$\|PZ\|^2 = Z^T P^T P Z = Z^T P Z = Z^T U \Lambda U^T Z$$

נזכור כי העי"ע של מטריצת הטלה הם 0 ו-1 בריבוי r ו- r בהתאמה. נסתכל על המ"מ $\tilde{Z} := U^T Z \in \mathbb{R}^n$

זו קומבינציה לינארית של וקטור רב נורמלי ולכן גם הוא מפולג רב נורמלית. תוחלתו: $U^T E(Z) = 0$ ומטריצת השוניות שלו:

$$\text{Var}(U^T Z) = U^T I U = I$$

כלומר גם הוא וקטור רב נורמלי סטנדרטי. נציב בפירוק הספקטרלי ונקבל:

$$Z^T U \Lambda U^T Z = \sum_{i=1}^n \tilde{Z}_i^2 \lambda_i = \sum_{i=1}^r \tilde{Z}_i^2$$

זהו סכום של r מ"מ ב"ת ש"ה נורמליים סטנדרטיים ולכן מפולגים χ_r^2 .

ג.

$$\|e\|^2 = \|Y - \hat{Y}\|^2 = \|(I - P_X)Y\|^2 = \|(I - P_X)X\beta + (I - P_X)\epsilon\|^2 = \|(I - P_X)\epsilon\|^2$$

כעת כיוון ש- $\epsilon \sim N(0, \sigma^2 I)$ אז ניתן לכתוב את $\epsilon = \sigma Z$ בעבור $Z \sim N(0, I)$ ומכאן:

$$\|(I - P_X)\epsilon\|^2 = \sigma^2 \|(I - P_X)Z\|^2 = \sigma^2 \chi_{n-p-1}^2$$

כאשר השיויון האחרון נובע מסעיף ב'.

ד.

$$\chi_q^2 \text{ כיוון ש-} \Sigma \text{ סימטרית חיובית, נוכל לכתוב } \left\| \Sigma^{-\frac{1}{2}}(Z - \mu) \right\|^2 = (Z - \mu)^T \Sigma^{-1}(Z - \mu).$$

שימו לב שזוהי נורמה בריבוע של וקטור מקרי נורמלי סטנדרטי, ולכן מפולגת χ_q^2 .

ה. כפי שראינו בתרגול ובשיעור, תחת הנחת הנורמליות המשתנים:

$$\begin{aligned} \hat{Y} &= X\hat{\beta} = P_X Y \sim N(X\beta, \sigma^2 X(X^T X)^{-1} X^T) = N(X\beta, \sigma^2 P_X) \\ e &= (I - P_X)Y \sim N(0, \sigma^2(I - P_X)) \end{aligned}$$

לכן אם המשתנים ב"מ הם גם יהיו ב"ת:

$$\text{Cov}(\hat{Y}, \hat{e}) = \text{Cov}(P_X Y, (I - P_X)Y) = P_X \cdot \text{Var}(Y)(I - P_X)^T = P_X \sigma^2 (I - P_X) = 0$$

הפונקצייה $f = g: R^n \rightarrow R$ היא:

$$f(v) = \sum_{i=1}^n v_i^2$$

ו.

$$\hat{Y} - X\beta = P_X Y - X\beta = P_X X\beta + P_X \epsilon - X\beta = X\beta + P_X \epsilon - X\beta = P_X \epsilon$$

אזי

$$\|\hat{Y} - X\beta\|^2 = \|P_X Y - X\beta\|^2 = \|P_X \epsilon\|^2$$

תוך שימוש בסעיף ב', זה מתפלג $\sigma^2 \chi_{p+1}^2$.

כמו כן, הוכחנו כבר בשיעור (ושוב- תוך שימוש בסעיף ב') כי $\|e\|^2 \sim \sigma^2 \chi_{n-p-1}^2$. לכן הסטטיסטי שבשאלה שקול ל:

$$T := \frac{\frac{\|\hat{Y} - X\beta\|^2}{\sigma^2}}{\frac{\|e\|^2}{\sigma^2}} = \frac{V_1}{V_2}$$

עבור $V_1 \sim \sigma^2 \chi_{p+1}^2$ ואילו $V_2 \sim \sigma^2 \chi_{n-p-1}^2$ ושני המשתנים בלתי תלויים (מהסעיף הקודם). לאחר חלוקה של המונה ב- $p+1$ ושל המכנה ב- $n-p-1$ נקבל בדיוק את ההגדרה של משתנה מקרי המפולג

$$\frac{n-p-1}{p+1} T \sim F_{p+1, n-p-1} \Leftrightarrow T \sim \frac{p+1}{n-p-1} F_{p+1, n-p-1} \text{ כלומר: } F_{p+1, n-p-1}$$

ז. תחת המודל הנורמלי מתקיים:

$$\hat{\beta}_j \sim N(\beta, \sigma^2 s_j)$$

$$(\hat{\beta}_j - \beta_j) / \sqrt{(\hat{\sigma}^2 s_j)} = [(\hat{\beta}_j - \beta_j) / \sigma \cdot \sqrt{s_j}] / \sqrt{(\hat{\sigma}^2)} / \sigma$$

המונה מפולג נורמלי סטנדרטי בעוד שבמכנה ישנו שורש על פני

התפלגות t_{n-p-1} . כלומר חי בריבוע המחולק בדרגות החופש שלו. מכאן שההתפלגות היא $\frac{\|e\|^2}{\sigma^2 \cdot n-p-1} = \hat{\sigma}^2 / \sigma^2 = \frac{\chi_{n-p-1}^2}{n-p-1}$

שאלה

א. מצאו את ההתפלגות של $\hat{\beta}_j$ ובנו רווח סמך ל- β_j כאשר σ^2 ידוע. חזרו על כך כאשר σ^2 איננו ידוע.

פתרון:

א. ע"פ השאלה הקודמת, ההתפלגות נורמלית עם הפרמטרים שהוזכרו. מכאן שרווח סמך ל- β_j :

$$\hat{\beta}_j \pm Z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{(X^T X)_{jj}}$$

וכאשר σ^2 איננו ידוע:

$$\hat{\beta}_j \pm t_{n-p-1, 1-\frac{\alpha}{2}} \cdot \frac{\hat{\sigma}}{(X^T X)_{jj}}$$


```
Call:
lm(formula = TotalMurderRate ~ Population + Density + Ownership,
    data = guns)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-2.2783	-1.3871	-0.3493	0.9758	5.9019

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.84193	1.02830	1.791	0.0797 .
Population	0.09146	A	2.238	0.0300 *
Density	1.91414	0.20841	9.184	4.63e-12 ***
Ownership	B	2.23611	1.258	0.2146

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.816 on 47 degrees of freedom
 Multiple R-squared: 0.6835, Adjusted R-squared: C
 F-statistic: 33.83 on D and 47 DF, p-value: 8.432e-12

	intercept	Population	Density	Ownership
intercept	0.3205745	-0.0073787	-0.0360011	-0.6548395
Population	-0.0073787	0.0005063	0.0006838	0.0109158
Density	-0.0360011	0.0006838	0.0131685	0.0721368
Ownership	-0.6548395	0.0109158	0.0721368	1.5159148

3. (10 נק') נניח, היפותטית, שהיתה מדינה 52 שלא כלולה בקובץ הנתונים המקורי, ועבורה המשתנים המסבירים מקבלים את הערכים: $\text{Population} = 9.53$, $\text{density} = 0.2$, $\text{ownership} = 0.63$. מצאו אומד ליניארי חסר-הטייה בעל שונות מינימלית עבור תוחלת שיעור מקרי הרצח במדינה עם המאפיינים האלה (שהמודל הליניארי שמתאר את הקשר בין המשתנים עבור קובץ הנתונים המקוריים, מתאים גם לתצפית החדשה).
4. (10 נק') בנו ר"ס ברמת ביטחון 90% עבור הפרמטר שנאמד בסעיף הקודם. יש לציין אילו הנחות נדרשות על השגיאות ϵ_i כדי שרווח-הסמך אכן יהיה תקף.

4. אומר פרופ' ליניארי נלסן, $\theta = a^T \beta$, כפאליה הריגל פוא $\hat{\theta} = a^T \hat{\beta}$,
 ומקיים: $\text{Var}(\hat{\theta}) = \text{Var}(a^T \hat{\beta}) = a^T [(X^T X)^{-1}] a$.
 במקרה שלנו $a = (1, 9.53, 0.2, 0.63)^T$, ופאליה ריגל $(X^T X)^{-1}$.
 (חלק):

$$a^T [(X^T X)^{-1}] a = \sum_{i=1}^k \sum_{j=1}^k [(X^T X)^{-1}]_{ij} a_i a_j =$$

$$\begin{aligned}
&= 0.32 - .0073 \cdot 9.53 - \overset{0.036}{.36} \cdot 0.2 - .654 \cdot 0.63 + & (i=1) \\
&+ 9.53 (-.0073 + .0005 \cdot 9.53 + .0006 \cdot 0.2 + .011 \cdot 0.63) + & (i=2) \\
&+ 0.2 (-\overset{0.036}{.36} + .0006 \cdot 9.53 + .0131 \cdot 0.2 + 0.72 \cdot 0.63) + & (i=3) \\
&+ 0.63 (-.654 + .011 \cdot 9.53 + .072 \cdot 0.2 + 1.516 \cdot 0.63) & (i=4) \\
&= \boxed{0.14}
\end{aligned}$$

	1	9.53	0.2	0.63
1	0.32	-.0073	-.036	-.654
9.53	-.0073	.0005	.0006	+.011
0.2	-.036	.0006	.0131	.072
0.63	-.654	.011	.072	1.516

$$CI = \hat{\theta} \pm \hat{\sigma} \sqrt{a^T (X^T X)^{-1} a} \cdot t_{n-p-1; 1-\alpha/2} \quad \text{דבסוס}$$

$$= 4.865 \pm 1.816 \cdot \sqrt{0.14} \cdot 1.678$$

$$= 4.865 \pm 1.14 = \boxed{(3.72, 6)}$$

היום תקף הסתכלות על משתנה ϵ_i (בניגוד לבניגוד הראשון) כהערכה
(הערכה: ערכים; משתנה: משתנה) וחסרית למעשה בניגוד.

שאלות נוספות- לקראת בוחן האמצע:

1. נניח כי בידינו נתונים על הגיל (X_1), המשקל (X_2), ועל לחץ הדם (Y) של n מטופלים. כמו כן, הניחו כי ידוע שהמשקל לא משפיע כלל על לחץ הדם בהינתן הגיל. נסמן ב- M את המרחב הנפרש על ידי עמודות המטריצה X . נסמן ב- L את המרחב הנפרש על ידי עמודות המטריצה X כשהשמטנו ממנה את עמודות המשקלים.
האם הטענות הבאות נכונות או לא נכונות? נמקו.

א. $P_M Y$ הוא אומד מוטה ל- $E(Y|X)$.

ב. $E||e_M||^2 > E||e_L||^2$.

א. הטענה לא נכונה. אינטואיטיבית- זה כמו להגיד $\beta_2 = 0$. כיוון שתחת הנחות המודל הלינארי אומד ריבועים פחותים הוא אומד חסר הטיה, נקבל $E(\hat{\beta}_2) = \beta_2 = 0$. באופן פורמלי יותר:

$$E(P_M Y) = P_M E(Y) = P_M X_L \beta = X_L \beta$$

כאשר המעבר האחרון נכון כיוון ש- $L \subseteq M$.

ב. הטענה לא נכונה.

$$\begin{aligned} \|e_L\|^2 &= \|(I - P_L)Y\|^2 = Y^T U \Lambda U^T Y = \tilde{Y}^T \Lambda \tilde{Y} = \sum_{i=1}^{n-p} \tilde{Y}_i^2 \geq \sum_{i=1}^{n-p-1} \tilde{Y}_i^2 = \|(I - P_M)Y\|^2 \\ &= \|e_M\|^2. \end{aligned}$$

2. הוכיחו כי

10. If Z is another $n \times m$ matrix s.t. $\text{Im}(Z) = \text{Im}(X)$, then $P_Z = P_X$.

3.

Proposition 6. We have

$$1. I - P_X = P_{\text{Im}(X)^\perp}$$

$$2. \text{ if } L \text{ and } M \text{ are two subspaces of } \mathbb{R}^n \text{ with } L \subseteq M, \text{ then } P_M - P_L = P_{M \cap L^\perp}$$

ראו פתרון ברשימות השיעור.
עבור שאלה 3 סעיף 2:

$$\forall v \in \mathbb{R}^n:$$

$$w := (P_M - P_L)v = P_M v - P_L v \Rightarrow w \in M$$

כי $P_M v \in M$ וכן $P_L v \in L \subseteq M$ ולכן גם ההפרש (תת מרחב).
מצד שני, ניקח $u \in L$ אז:

$$u^T w = u^T P_M v - u^T P_L v = u^T P_M^T v - u^T P_L^T v = (P_M u)^T v - (P_L u)^T v = u^T v - u^T v = 0$$

ולכן $w \in L^\perp$.

נותר להראות כי זו מטריצה סימטרית ואיידמפוטנטית:

$$\begin{aligned} (P_M - P_L)^T &= \\ P_M^T - P_L^T &= P_M - P_L \end{aligned}$$

וכן:

$$(P_M - P_L)(P_M - P_L) = P_M^2 - P_L P_M - P_M P_L + P_L^2 = P_M - P_L$$

כאשר השתמשנו בכך שאם $L \subseteq M$ אז:

$$P_L P_M = P_M P_L = P_L$$